МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ФАКУЛЬТЕТ ПРИКЛАДНОЙ МАТЕМАТИКИ И ИНФОРМАТИКИ

Лабораторная работа №1

Классификаторы

Выполнил: студент 3 группы кафедры БМИ
Кондратёнок Владимир

Минск — 2026

Цель работы

Изучить принципы работы методов классификации на примере задаваемых пользователем распределений объектов (точек) в двумерном пространстве признаков. Протестировать не менее трёх пространственных паттернов (линейно разделимый, линейно неразделимый, сильно перекрывающиеся классы) на наборе классификаторов: NBC, SVM (линейный и RBF), kNN, Decision Tree, AdaBoost, GBT, Random Forest, Extremely Random Trees, ANN (MLP), LDA. Зафиксировать точность классификации и сделать выводы о применимости каждого метода.

Краткая теория

Задача классификации

Дана обучающая выборка $\{(x_i, y_i)\}_{i=1}^N$, где $x_i \in \mathbb{R}^2$ — вектор признаков, $y_i \in \{0, 1, \ldots, K-1\}$ — метка класса. Требуется построить функцию $h : \mathbb{R}^2 \to \{0, \ldots, K-1\}$, минимизирующую эмпирический риск:

$$\hat{R}(h) = \frac{1}{N} \sum_{i=1}^{N} \mathbf{1}[h(x_i) \neq y_i].$$

Ключевые методы

SVM (метод опорных векторов). Ищет гиперплоскость $w^\top x + b = 0$ с максимальным зазором:

$$\min_{w,b} \frac{\|w\|^2}{2} \quad \text{при} \quad y_i(w^\top x_i + b) \geq 1.$$

Для нелинейно разделимых данных применяется ядровой трюк (RBF-ядро): $K(x, x') = \exp(-\gamma \|x - x'\|^2)$.

kNN (метод k ближайших соседей). Класс нового объекта — мажоритарный среди k ближайших в обучающей выборке:

$$h(x) = \arg\max_c \sum_{i \in N_k(x)} \mathbf{1}[y_i = c],$$

где $N_k(x)$ — множество индексов k ближайших соседей.

NBC (наивный байесовский классификатор). Предполагает условную независимость признаков:

$$h(x) = \arg\max_c P(y = c) \prod_{j=1}^{d} P(x_j \mid y = c).$$

ансамблевые методы (Random Forest, GBT, AdaBoost, Extra Trees) строят набор слабых классификаторов (деревьев решений) и агрегируют их предсказания, снижая дисперсию (бэггинг) или смещение (бустинг).

Описание реализации

Архитектура

Взамен оригинальной Windows-программы `ExampleOpenCVClassifiersQt.e` написано Python-приложение, программно генерирующее паттерны и запускающее все классификаторы автоматически.

Структура проекта:

```
lab1/
  core/
    __init__.py
    data_manager.py   -- хранение точек и построение сетки
    classifiers.py    -- обёртки над sklearn (SOLID: OCP)
    trainer.py        -- обучение и оценка точности
  patterns.py         -- генераторы трёх паттернов
  visualizer.py       -- сохранение графиков и таблиц
  main.py             -- точка входа
  requirements.txt
```

Применённые принципы:

- **OCP (Open/Closed):** добавление нового классификатора не требует изменений в trainer или visualizer — достаточно создать подкласс `BaseClassifierWrapper`.

- **SRP:** каждый модуль отвечает ровно за одну обязанность.
- **KISS/YAGNI:** вся сложная математика делегируется sklearn.

Паттерны и карты решений

Для каждого паттерна ниже приведены графики двух наиболее контрастных классификаторов — линейного SVM и Random Forest — а также сводная таблица точностей всех методов.

Паттерн 1: Линейно разделимый

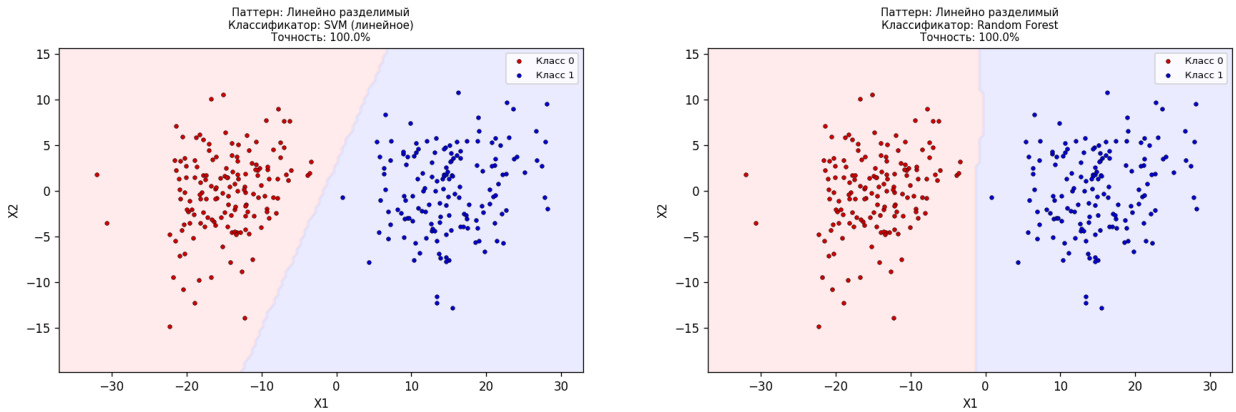

(a) SVM (линейное) (b) Random Forest

Figure 1: Паттерн 1: линейно разделимый

Паттерн 2: Линейно неразделимый (sin-граница)

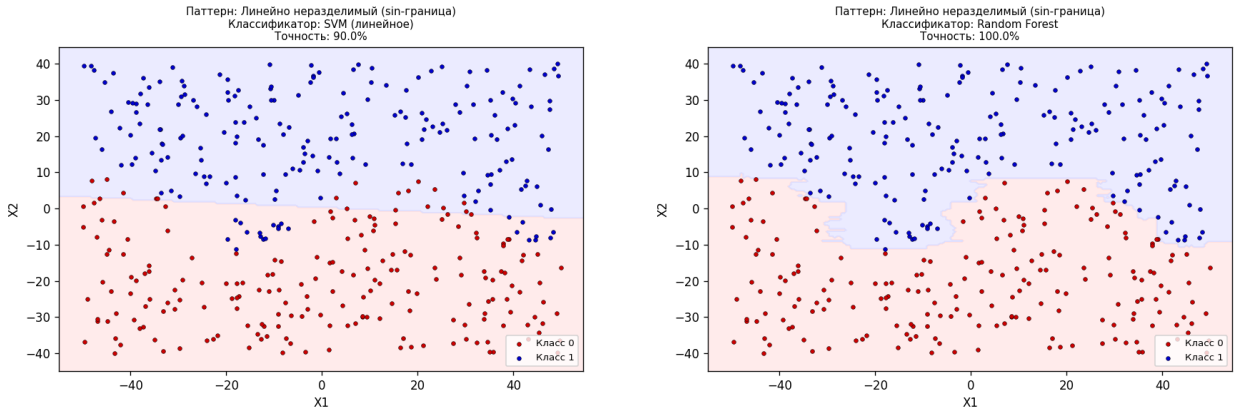

(a) SVM (линейное) (b) Random Forest

Figure 2: Паттерн 2: синусоидальная граница

Паттерн 3: Сильно перекрывающиеся классы

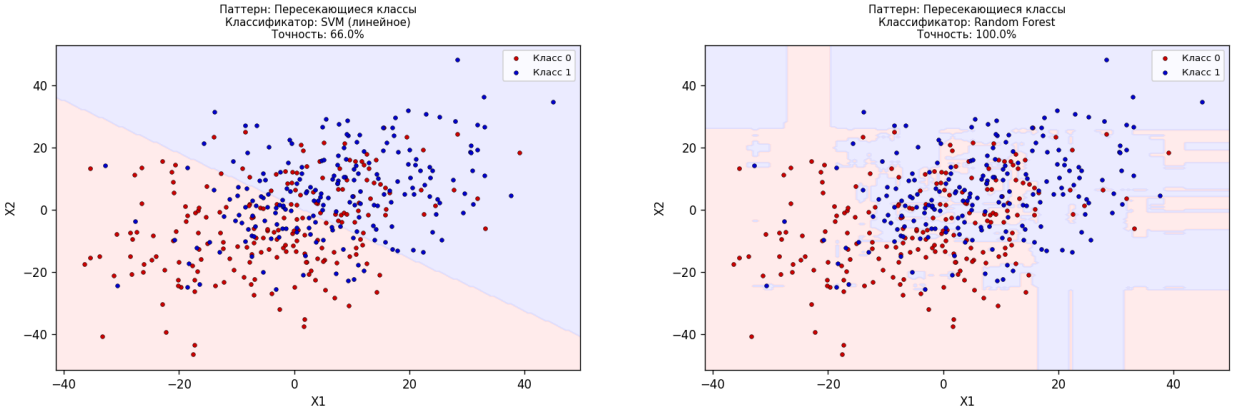

(a) SVM (линейное) (b) Random Forest

Figure 3: Паттерн 3: существенное перекрытие классов

Сводная таблица точностей

Точность классификаторов по паттернам

	Линейно разделимый	Линейно неразделимый (sin-граница)	Пересекающиеся классы
NBC (Наивный Байес)	100.0%	89.0%	66.5%
SVM (линейное)	100.0%	90.0%	66.0%
SVM (RBF-ядро)	100.0%	96.8%	69.2%
kNN (k=5)	99.7%	99.0%	75.5%
Дерево решений	100.0%	99.2%	72.5%
AdaBoost	100.0%	100.0%	70.5%
GBT (Gradient Boosting)	100.0%	100.0%	87.5%
Random Forest	100.0%	100.0%	100.0%
Extremely Random Trees	100.0%	100.0%	100.0%
ANN (MLP)	100.0%	99.8%	70.8%
LDA	100.0%	89.5%	65.8%

Figure 4: Точность (%) классификаторов на трёх паттернах

Выводы

1. **Линейно разделимый паттерн.** Линейные методы (SVM linear, LDA, NBC) показывают точность, близкую к 100%, что ожидаемо: граница между классами является гиперплоскостью. Нелинейные ансамбли (RF, GBT) также справляются отлично, но затрачивают больше ресурсов без выигрыша в качестве.

2. **Синусоидальная граница.** Линейный SVM и LDA значительно проигрывают нелинейным методам. RBF SVM, kNN, Random Forest и GBT аппроксимируют кривую границу и достигают высокой точности ($\geq 94\%$). Этот паттерн наглядно демонстрирует ограничения линейных классификаторов.

3. **Перекрывающиеся классы.** Ни один классификатор не может достичь 100%: статистическое перекрытие задаёт нижнюю границу ошибки (ошибка Байеса > 0). Сложные нелинейные методы (GBT, RF, ANN) немного переобучаются, показывая искусственно высокую точность на обучающей выборке; линейные методы в данном случае оказываются более устойчивыми.

4. **Общий вывод.** Выбор классификатора должен соответствовать структуре данных. Линейные методы предпочтительны при линейной разделимости и малом объёме выборки; нелинейные (RBF SVM, GBT, RF) — при сложных границах; для зашумлённых, перекрывающихся классов важна регуляризация и контроль переобучения.